معماری RAG

چکیده

با پیشرفت فناوری هوش مصنوعی و توسعه مدل‌های زبانی بزرگ(Large Language Models) ، استفاده از این مدل‌ها در زمینه‌های مختلف علمی، صنعتی، آموزشی و تجاری گسترش یافته است. مدل‌های زبانی بزرگ مانند GPT توانایی قابل‌توجهی در درک زبان طبیعی، تولید متن، پاسخ‌گویی به سؤالات و تحلیل اطلاعات دارند. با این حال، این مدل‌ها با محدودیت‌هایی مانند تولید اطلاعات نادرست، نداشتن دسترسی مستقیم به اطلاعات به‌روز، محدودیت دانش ذخیره‌شده در زمان آموزش و ناتوانی در دسترسی به اطلاعات اختصاصی سازمان‌ها مواجه هستند.

یکی از فناوری‌هایی که برای رفع بخشی از این محدودیت‌ها توسعه یافته، معماری RAG یا Retrieval-Augmented Generation است. این معماری با ترکیب دو قابلیت اصلی، یعنی بازیابی اطلاعات از منابع خارجی و تولید پاسخ توسط مدل زبانی، تلاش می‌کند پاسخ‌هایی دقیق‌تر، مرتبط‌تر و مبتنی بر اسناد معتبر ارائه دهد.

در معماریRAG ، ابتدا اطلاعات مورد نیاز از منابع داده‌ای مختلف مانند اسناد متنی، فایل‌هایPDF ، پایگاه‌های داده و صفحات وب استخراج و آماده‌سازی می‌شوند. سپس این اطلاعات به قطعات کوچک‌تر تقسیم شده و با استفاده از مدل‌های تعبیه‌سازی (Embedding Models) به بردارهای عددی تبدیل می‌شوند. در مرحله بعد، بردارها در یک پایگاه داده برداری ذخیره می‌شوند. هنگامی که کاربر سؤالی مطرح می‌کند، سیستم با استفاده از روش‌های بازیابی اطلاعات، مرتبط‌ترین بخش‌های داده را پیدا کرده و آن‌ها را به‌عنوان زمینه (Context) در اختیار مدل زبانی قرار می‌دهد. مدل زبانی با استفاده از این اطلاعات پاسخ نهایی را تولید می‌کند.

هدف این تحقیق، بررسی مفهومRAG ، تاریخچه شکل‌گیری آن، اجزای اصلی معماری، نحوه عملکرد، الگوریتم‌ها و روش‌های بازیابی، انواع معماری‌هایRAG ، کاربردها، مزایا، چالش‌ها و آینده این فناوری است. همچنین در این تحقیق تلاش می‌شود نقش RAG در افزایش قابلیت اعتماد سیستم‌های هوش مصنوعی و توسعه سامانه‌های هوشمند مبتنی بر دانش بررسی شود.

واژگان کلیدی: هوش مصنوعی، مدل‌های زبانی بزرگ، RAG، بازیابی اطلاعات، تولید متن، پایگاه داده برداری، Embedding، پردازش زبان طبیعی، هوش مصنوعی مولد.

فهرست مطالب

۱ .مقدمه

۲ .آشنایی با مفاهیم پایه

۳ .تاریخچه و روند شکل‌گیری معماریRAG

۴ .تعریف معماری RAG و اهداف آن

۵ .اجزای اصلی معماریRAG

۶ .مراحل عملکرد سیستمRAG

۷ .بررسی روش‌های بازیابی اطلاعات

۸ .انواع معماری‌هایRAG

۹ .پایگاه‌های داده برداری و نقش آن‌ها درRAG

۱۰ .مقایسه RAG با روش‌های سنتی وFine-Tuning

۱۱ .کاربردهای معماریRAG

۱۲ .مزایای استفاده ازRAG

۱۳ .چالش‌ها و محدودیت‌های معماریRAG

۱۴ .امنیت و حریم خصوصی در سیستم‌هایRAG

۱۵ .ارزیابی و سنجش عملکرد سیستم‌هایRAG

۱۶ .نمونه عملی طراحی یک سامانه مبتنی برRAG

۱۷ .آینده معماریRAG

۱۸ .نتیجه‌گیری

۱۹ .منابع و مراجع

#فصل اول: مقدمه

##۱-۱ .مقدمه‌ای بر هوش مصنوعی و مدل‌های زبانی بزرگ

هوش مصنوعی یکی از مهم‌ترین فناوری‌های عصر حاضر است که هدف آن طراحی سیستم‌هایی است که بتوانند وظایفی مشابه توانایی‌های شناختی انسان را انجام دهند. این وظایف شامل یادگیری، استدلال، تشخیص الگو، پردازش زبان طبیعی، تصمیم‌گیری و حل مسئله هستند.

در سال‌های اخیر، یکی از مهم‌ترین پیشرفت‌های هوش مصنوعی، توسعه مدل‌های زبانی بزرگ یاLLM ها بوده است. این مدل‌ها با استفاده از حجم بسیار زیادی از داده‌های متنی آموزش داده می‌شوند و می‌توانند ساختار زبان انسان را یاد بگیرند. در نتیجه، توانایی تولید متن، پاسخ‌گویی به پرسش‌ها، خلاصه‌سازی اسناد، ترجمه، برنامه‌نویسی و تحلیل اطلاعات را به دست می‌آورند.

مدل‌های زبانی بزرگ معمولاً بر اساس معماری Transformer طراحی می‌شوند. معماری ترنسفورمر از مکانیزمی به نام Attention استفاده می‌کند که به مدل اجازه می‌دهد ارتباط میان بخش‌های مختلف یک متن را شناسایی کند.

با وجود توانایی‌های گسترده، مدل‌های زبانی بزرگ مشکلاتی نیز دارند. یکی از مهم‌ترین این مشکلات، پدیده‌ای به نام توهم هوش مصنوعی (AI Hallucination)است. منظور از توهم، تولید اطلاعاتی است که از نظر ظاهری منطقی و معتبر به نظر می‌رسند، اما ممکن است نادرست، ساختگی یا فاقد منبع قابل اعتماد باشند.

برای مثال، ممکن است یک مدل زبانی در پاسخ به سؤالی درباره یک قانون جدید، اطلاعات قدیمی ارائه دهد یا حتی ماده قانونی‌ای را ذکر کند که وجود خارجی ندارد.

مشکل دیگر این است که دانش مدل‌های زبانی به داده‌هایی وابسته است که در فرآیند آموزش در اختیار آن‌ها قرار گرفته است. بنابراین، این مدل‌ها الزاماً به اطلاعات جدید یا داده‌های خصوصی یک سازمان دسترسی ندارند.

این محدودیت‌ها باعث شده است پژوهشگران به دنبال روش‌هایی باشند که بتوانند مدل‌های زبانی را به منابع اطلاعاتی خارجی متصل کنند.

یکی از مهم‌ترین راهکارهای ارائه‌شده در این زمینه، معماری RAG است.

##۱-۲ .ضرورت استفاده از معماریRAG

در بسیاری از کاربردهای واقعی، پاسخ‌گویی صرفاً بر اساس اطلاعات عمومی کافی نیست. برای مثال، یک شرکت ممکن است بخواهد سامانه‌ای طراحی کند که بتواند به سؤالات کارکنان درباره آیین‌نامه‌های داخلی، قراردادها، دستورالعمل‌ها و گزارش‌های سازمان پاسخ دهد.

مدل زبانی عمومی معمولاً به این اطلاعات اختصاصی دسترسی ندارد. آموزش مجدد مدل برای وارد کردن تمام این اطلاعات نیز می‌تواند هزینه‌بر و زمان‌بر باشد.

معماری RAG این مشکل را با اتصال مدل زبانی به یک منبع اطلاعاتی خارجی حل می‌کند.

به کمک این روش، اطلاعات سازمان می‌توانند بدون نیاز به آموزش مجدد مدل، به سامانه اضافه یا به‌روزرسانی شوند. هنگامی که کاربر سؤالی مطرح می‌کند، سیستم ابتدا اطلاعات مرتبط را بازیابی کرده و سپس مدل زبانی را برای تولید پاسخ مبتنی بر آن اطلاعات به کار می‌گیرد.

از این رو، RAGمی‌تواند در ایجاد سامانه‌های پاسخ‌گویی هوشمند، دستیارهای سازمانی، سامانه‌های آموزشی و موتورهای جست‌وجوی پیشرفته نقش مهمی داشته باشد.

###۱-۳ .اهداف تحقیق

اهداف اصلی این تحقیق عبارت‌اند از:

۱ .آشنایی با مفهوم معماری.Retrieval-Augmented Generation

۲ .بررسی ساختار و اجزای اصلی سیستم‌های.RAG

۳ .شناخت فرآیند ذخیره‌سازی و بازیابی اطلاعات.

۴ .بررسی نقش مدل‌های زبانی بزرگ در تولید پاسخ.

۵ .آشنایی با پایگاه‌های داده برداری و مدل‌های.Embedding

۶ .مقایسه معماری RAG با روش.Fine-Tuning

۷ .بررسی کاربردهای RAG در حوزه‌های مختلف.

۸ .شناخت مزایا، محدودیت‌ها و چالش‌های امنیتی این معماری.

۹ .بررسی روش‌های ارزیابی عملکرد سیستم‌های.RAG

۱۰ .شناخت روندهای آینده و توسعه این فناوری.

###۱-۴ .اهمیت موضوع

اهمیت معماری RAG از آن جهت است که فاصله میان توانایی تولید متن توسط مدل‌های زبانی و نیاز به استفاده از اطلاعات واقعی و قابل استناد را کاهش می‌دهد.

این معماری امکان استفاده از دانش تخصصی و به‌روز را فراهم می‌کند و باعث می‌شود سازمان‌ها بتوانند بدون آموزش مجدد مدل‌های بزرگ، اطلاعات اختصاصی خود را در اختیار سیستم‌های هوش مصنوعی قرار دهند.

همچنین با امکان ارجاع به اسناد منبع، بررسی صحت پاسخ‌ها و کنترل بهتر اطلاعات فراهم می‌شود. البته استفاده از RAG به‌تنهایی صحت پاسخ را تضمین نمی‌کند و کیفیت نهایی همچنان به کیفیت منابع، بازیابی و نحوه تولید پاسخ وابسته است.

#فصل دوم: آشنایی با مفاهیم پایه

برای درک صحیح معماریRAG ، ابتدا باید با چند مفهوم اساسی در حوزه هوش مصنوعی و پردازش اطلاعات آشنا شویم.

##۲-۱ .مدل زبانی بزرگ(LLM)

مدل زبانی بزرگ یا Large Language Model نوعی مدل هوش مصنوعی است که با استفاده از حجم زیادی از داده‌های متنی آموزش داده می‌شود.

این مدل‌ها با یادگیری الگوهای زبانی می‌توانند کلمات و جملات را در ارتباط با یکدیگر تحلیل کنند و متن جدید تولید کنند.

مدل‌های زبانی بزرگ معمولاً دارای تعداد زیادی پارامتر هستند. پارامترها مقادیر عددی‌ای هستند که در فرآیند آموزش تنظیم می‌شوند و دانش آماری مدل را شکل می‌دهند.

از مهم‌ترین توانایی‌های این مدل‌ها می‌توان به موارد زیر اشاره کرد:

-پاسخ‌گویی به پرسش‌های کاربران
-خلاصه‌سازی متون طولانی
-ترجمه زبان‌ها
-تولید محتوای متنی
-تحلیل و طبقه‌بندی اطلاعات
-تولید و توضیح کدهای برنامه‌نویسی
-استخراج اطلاعات از اسناد

با این وجود، LLMها الزاماً پایگاه اطلاعاتی دقیق و قابل جست‌وجویی از تمام دانسته‌های خود در اختیار ندارند. اطلاعات آن‌ها عمدتاً در پارامترهای مدل به شکل توزیع‌شده بازنمایی شده است.

به همین دلیل، دسترسی به اطلاعات خارجی می‌تواند عملکرد آن‌ها را در وظایف دانش‌محور بهبود دهد.

##۲-۲ .پردازش زبان طبیعی(NLP)

پردازش زبان طبیعی یا Natural Language Processing شاخه‌ای از هوش مصنوعی است که به تعامل میان کامپیوتر و زبان انسان می‌پردازد.

هدف NLP این است که کامپیوتر بتواند زبان طبیعی را تحلیل، تفسیر و تولید کند.

برخی از کاربردهای پردازش زبان طبیعی عبارت‌اند از:

-تشخیص موجودیت‌های نام‌دار
-تحلیل احساسات
-ترجمه ماشینی
-استخراج اطلاعات
-پاسخ‌گویی به سؤالات
-دسته‌بندی متون
-خلاصه‌سازی اسناد

معماری RAG از تکنیک‌های پردازش زبان طبیعی برای آماده‌سازی اسناد، درک پرسش کاربران و تولید پاسخ استفاده می‌کند.

۲-۳ Embedding .یا تعبیه‌سازی برداری

یکی از مهم‌ترین مفاهیم در معماریRAG ، Embeddingاست.

Embeddingفرآیندی است که طی آن یک متن، کلمه، جمله یا سند به یک بردار عددی در فضای چندبعدی تبدیل می‌شود.

برای مثال، جمله زیر را در نظر بگیرید:

»هوش مصنوعی در پزشکی کاربردهای فراوانی دارد«.

مدل Embedding این جمله را به مجموعه‌ای از اعداد تبدیل می‌کند. این اعداد نشان‌دهنده ویژگی‌های معنایی متن هستند.

نکته مهم این است که متن‌هایی که از نظر معنایی به یکدیگر نزدیک هستند، معمولاً بردارهای نزدیک‌تری نیز خواهند داشت.

برای مثال، جملات زیر از نظر معنا به یکدیگر نزدیک هستند:

-هوش مصنوعی در تشخیص بیماری کاربرد دارد.
-سیستم‌های هوشمند می‌توانند به پزشکان در تشخیص بیماری کمک کنند.

اگر این جملات با یک مدل Embedding مناسب تبدیل شوند، بردارهای آن‌ها معمولاً شباهت معنایی بالایی خواهند داشت.

به همین دلیل، سیستم RAG می‌تواند به جای جست‌وجوی صرفاً کلمه‌محور، اطلاعات را بر اساس مفهوم و معنای آن‌ها بازیابی کند.

۲-۴ Vector Database .یا پایگاه داده برداری

پایگاه داده برداری نوعی سیستم ذخیره‌سازی است که برای نگهداری و جست‌وجوی بردارهای عددی طراحی شده است.

در معماریRAG ، اسناد پس از تبدیل به Embedding در این پایگاه داده ذخیره می‌شوند.

هنگامی که کاربر سؤالی مطرح می‌کند، پرسش او نیز به یک بردار تبدیل می‌شود. سپس سیستم با مقایسه بردار پرسش و بردار اسناد، نزدیک‌ترین نتایج را پیدا می‌کند.

از جمله فناوری‌های مورد استفاده در این زمینه می‌توان به موارد زیر اشاره کرد:

- FAISS
- Milvus
- Qdrant
- Weaviate
- Chroma
- Pinecone

این فناوری‌ها امکانات مختلفی برای ذخیره‌سازی بردارها، جست‌وجوی شباهت، فیلتر کردن اطلاعات و مدیریت داده‌ها ارائه می‌دهند.

##۵-۲ .مفهوم Retrieval یا بازیابی اطلاعات

Retrievalبه فرآیند پیدا کردن اطلاعات مرتبط با یک پرسش یا نیاز مشخص گفته می‌شود.

در سیستم‌های سنتی، بازیابی اطلاعات معمولاً بر اساس تطبیق کلمات کلیدی انجام می‌شود. برای مثال، اگر کاربر عبارت «مزایای انرژی خورشیدی» را جست‌وجو کند، موتور جست‌وجو صفحاتی را پیدا می‌کند که این کلمات در آن‌ها وجود دارند.

اما در بازیابی معنایی، سیستم تلاش می‌کند مفهوم پرسش را درک کند و اسنادی را پیدا کند که از نظر معنایی به آن مرتبط هستند؛ حتی اگر دقیقاً همان کلمات در متن وجود نداشته باشند.

این قابلیت یکی از ویژگی‌های مهم RAG محسوب می‌شود.

#فصل سوم: تاریخچه و روند شکل‌گیری معماریRAG

##۱-۳ .تحولات اولیه بازیابی اطلاعات

ایده بازیابی اطلاعات از منابع خارجی پیش از ظهور مدل‌های زبانی بزرگ وجود داشته است.

در موتورهای جست‌وجوی سنتی، اسناد در یک ساختار قابل جست‌وجو ذخیره می‌شدند و کاربران با وارد کردن کلمات کلیدی می‌توانستند به اطلاعات مورد نظر دسترسی پیدا کنند.

با توسعه یادگیری ماشین و یادگیری عمیق، روش‌های بازیابی اطلاعات نیز پیشرفته‌تر شدند.

مدل‌های زبانی و شبکه‌های عصبی امکان نمایش معنایی متن را فراهم کردند و به این ترتیب، جست‌وجوی معنایی به یکی از موضوعات مهم پژوهشی تبدیل شد.

۳-۲. ظهور مدل‌های زبانی بزرگ

با توسعه شبکه‌های عصبی عمیق و معماری Transformer در سال ۲۰۱۷، زمینه برای ساخت مدل‌های زبانی قدرتمندتر فراهم شد.

مدل‌هایی مانند BERT و GPT توانستند در بسیاری از وظایف پردازش زبان طبیعی عملکرد قابل‌توجهی ارائه دهند.

با این حال، این مدل‌ها همچنان به اطلاعات موجود در فرآیند آموزش وابسته بودند و در مواجهه با اطلاعات جدید یا اختصاصی با محدودیت روبه‌رو می‌شدند.

۳-۳. معرفی رسمی معماری RAG

یکی از پژوهش‌های بنیادی در معرفی معماری RAG ، مقاله‌ای با عنوان زیر است:

Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks

این مقاله در سال ۲۰۲۰ توسط Patrick Lewis و همکارانش منتشر شد.

پژوهشگران در این مقاله روشی را معرفی کردند که در آن حافظه پارامتری مدل زبانی با یک حافظه غیرپارامتری خارجی ترکیب می‌شد.

منظور از حافظه پارامتری، دانشی است که در پارامترهای مدل زبانی ذخیره شده است.

منظور از حافظه غیرپارامتری، اطلاعاتی است که در یک منبع خارجی مانند مجموعه اسناد و پایگاه داده نگهداری می‌شوند.

این پژوهش نشان داد که ترکیب بازیابی اطلاعات و تولید متن می‌تواند در بسیاری از وظایف دانش‌محور مفید باشد.

در مدل اولیه مقاله، اطلاعات از مجموعه بزرگی از اسناد ویکی‌پدیا بازیابی می‌شدند و سپس در اختیار مدل تولیدکننده قرار می‌گرفتند.

۳-۴. توسعه RAG در سال‌های بعد

پس از معرفی RAG ، این فناوری به‌سرعت مورد توجه پژوهشگران و شرکت‌های فعال در حوزه هوش مصنوعی قرار گرفت.

با گسترش مدل‌های زبانی بزرگ، استفاده از RAG به روشی کاربردی برای اتصال مدل‌ها به اسناد اختصاصی و منابع اطلاعاتی خارجی تبدیل شد.

در ادامه، روش‌های پیشرفته‌تری مانندHybrid Search ، Reranking، Query Expansion، Graph RAGو Agentic RAG توسعه پیدا کردند.

هدف این روش‌ها افزایش دقت بازیابی، بهبود کیفیت پاسخ و امکان حل مسائل پیچیده‌تر است.

امروزه RAG دیگر تنها یک روش ساده برای جست‌وجوی اسناد نیست، بلکه مجموعه‌ای از معماری‌ها و تکنیک‌ها برای اتصال مدل‌های زبانی به دانش خارجی محسوب می‌شود.

#فصل چهارم: تعریف معماری RAG و اهداف آن

##۴-۱ .تعریفRAG

عبارت Retrieval-Augmented Generation از سه بخش تشکیل شده است:

Retrieval:بازیابی اطلاعات مرتبط از منابع خارجی.

Augmented:تقویت فرآیند تولید پاسخ با اطلاعات بازیابی‌شده.

Generation:تولید پاسخ نهایی با استفاده از مدل زبانی.

بنابراین، RAGرا می‌توان معماری‌ای تعریف کرد که در آن مدل زبانی برای پاسخ‌گویی به پرسش کاربر، علاوه بر دانش داخلی خود، از اطلاعات بازیابی‌شده از منابع خارجی نیز استفاده می‌کند.

در یک سیستم معمولی، کاربر سؤال خود را مستقیماً به مدل زبانی ارسال می‌کند و مدل بر اساس دانش ذخیره‌شده در پارامترهای خود پاسخ می‌دهد.

اما در سیستمRAG ، پیش از تولید پاسخ، اطلاعات مرتبط با سؤال کاربر از یک منبع دانش خارجی بازیابی می‌شوند.

سپس پرسش کاربر همراه با اطلاعات بازیابی‌شده به مدل زبانی داده می‌شود.

در نتیجه، مدل می‌تواند پاسخ خود را بر اساس شواهد موجود در اسناد تولید کند.

##۴-۲ .اهداف اصلی معماریRAG

مهم‌ترین اهداف این معماری عبارت‌اند از:

۱ .افزایش دقت اطلاعات

با ارائه اسناد مرتبط به مدل، احتمال پاسخ‌گویی بر اساس اطلاعات نامرتبط یا ناقص کاهش پیدا می‌کند.

۲. کاهش توهم هوش مصنوعی

وقتی مدل به شواهد مشخص دسترسی داشته باشد، می‌تواند پاسخ خود را بر اساس اطلاعات موجود تنظیم کند. با این حال، RAGتوهم را به‌طور کامل حذف نمی‌کند.

۳. دسترسی به اطلاعات به‌روز

اطلاعات موجود در پایگاه دانش را می‌توان بدون آموزش مجدد مدل تغییر داد.

۴. استفاده از اطلاعات اختصاصی

سازمان‌ها می‌توانند اسناد داخلی خود را به سیستم متصل کنند.

۵. افزایش قابلیت ردیابی پاسخ‌ها

در صورت طراحی مناسب، سیستم می‌تواند مشخص کند هر پاسخ بر اساس کدام سند یا بخش از اسناد تولید شده است.

۶. کاهش نیاز به آموزش مجدد

در بسیاری از موارد، برای افزودن دانش جدید به سامانه نیازی به Fine-Tuning مجدد مدل نیست.

۳-۴. ساختار کلی معماریRAG

معماری عمومی RAG از دو بخش اصلی تشکیل شده است:

الف) بخش آماده‌سازی و ذخیره‌سازی اطلاعات(Indexing)

ب) بخش بازیابی و تولید پاسخ(Retrieval and Generation)

در بخش اول، داده‌های خام به اطلاعات قابل جست‌وجو تبدیل می‌شوند.

در بخش دوم، سیستم بر اساس پرسش کاربر اطلاعات مناسب را بازیابی کرده و آن‌ها را در اختیار مدل زبانی قرار می‌دهد.

جریان کلی عملکرد سیستم به شکل زیر است:

۱. دریافت اسناد و منابع اطلاعاتی

۲. استخراج متن از اسناد

۳ .پاک‌سازی و آماده‌سازی داده‌ها

۴ .تقسیم اسناد به قطعات کوچک‌تر

۵ .تبدیل قطعات به بردارهای عددی

۶ .ذخیره بردارها در پایگاه داده برداری

۷ .دریافت پرسش کاربر

۸ .تبدیل پرسش به بردار

۹ .بازیابی قطعات مرتبط

۱۰ .انتخاب و مرتب‌سازی اطلاعات مناسب

۱۱ .ارسال پرسش و اطلاعات بازیابی‌شده به مدل زبانی

۱۲ .تولید و ارائه پاسخ نهایی

#فصل پنجم: اجزای اصلی معماریRAG

##۵-۱ .منبع داده(Data Sources)

اولین بخش در معماریRAG ، منابع اطلاعاتی هستند.

منابع داده می‌توانند شامل انواع مختلف اطلاعات باشند:

-فایل‌هایPDF
-اسنادWord
-فایل‌های متنی
-صفحات وب
-پایگاه‌های داده رابطه‌ای
-گزارش‌های سازمانی
-فایل‌هایExcel
-مستندات فنی

-کتاب‌ها و مقالات علمی
-داده‌های ساختاریافته و غیرساختاریافته

کیفیت منابع داده تأثیر مستقیمی بر عملکرد سیستم دارد.

اگر اسناد اولیه دارای اطلاعات اشتباه، ناقص یا قدیمی باشند، سیستم RAG نیز ممکن است پاسخ‌های نادرست ارائه دهد.

بنابراین، پیش از ورود داده‌ها به سیستم باید کیفیت و اعتبار آن‌ها بررسی شود.

۵-۲. استخراج داده(Data Extraction)

در بسیاری از موارد، اطلاعات مورد نیاز در فایل‌هایی ذخیره شده‌اند که مستقیماً برای جست‌وجوی معنایی مناسب نیستند.

برای مثال، یک فایل PDF ممکن است شامل متن، تصویر، جدول و نمودار باشد.

در مرحله استخراج داده، اطلاعات قابل استفاده از این فایل‌ها استخراج می‌شوند.

برای استخراج متن از فایل‌های مختلف می‌توان از ابزارهای گوناگونی استفاده کرد.

برای نمونه:

PyMuPDF -برای پردازش فایل‌هایPDF
python-docx -برای خواندن فایل‌هایWord
BeautifulSoup -برای استخراج محتوای صفحات وب
Apache Tika -برای استخراج متن و فراداده از انواع فایل‌ها

در اسناد اسکن‌شده نیز ممکن است به فناوری OCR نیاز باشد.

OCRیا Optical Character Recognition فناوری تشخیص نوری کاراکتر است که متن موجود در تصاویر را به متن قابل پردازش تبدیل می‌کند.

۵-۳. پیش‌پردازش داده‌ها(Data Preprocessing)

پس از استخراج اطلاعات، باید داده‌ها پاک‌سازی و آماده‌سازی شوند.

این مرحله اهمیت زیادی دارد؛ زیرا اطلاعات نامرتب و دارای نویز می‌توانند کیفیت جست‌وجو را کاهش دهند.

برخی از عملیات پیش‌پردازش عبارت‌اند از:

-حذف بخش‌های تکراری
-اصلاح فاصله‌ها
-حذف نویسه‌های غیرضروری
-اصلاح ساختار متن
-یکسان‌سازی فرمت داده‌ها
-شناسایی زبان اسناد
-حذف اطلاعات نامعتبر
-استخراج عنوان و تاریخ اسناد
-حفظ ارتباط میان متن و منبع اصلی

در زبان فارسی، یکسان‌سازی حروف «ی» و «ک»، مدیریت نیم‌فاصله و اصلاح شکل‌های مختلف نگارشی نیز می‌تواند اهمیت داشته باشد.

###۴-۵ .تقسیم‌بندی اسناد(Chunking)

یکی از مهم‌ترین مراحل طراحیRAG ، تقسیم اسناد به قطعات کوچک‌تر است.

مدل‌های زبانی دارای محدودیت مشخصی در میزان اطلاعاتی هستند که می‌توانند در هر درخواست دریافت کنند.

به همین دلیل، معمولاً کل اسناد به‌صورت یکجا به مدل ارسال نمی‌شوند.

در عوض، اسناد به بخش‌های کوچک‌تری تقسیم می‌شوند که به آن‌ها Chunk گفته می‌شود.

برای مثال، فرض کنید یک فایل آموزشی دارای ۱۰۰ صفحه است. سیستم می‌تواند این فایل را به چند صد قطعه متنی تقسیم کند.

هر قطعه به‌صورت مستقل یا همراه با فراداده‌های مرتبط ذخیره می‌شود.

روش‌های رایج Chunking عبارت‌اند از:

۱ .تقسیم‌بندی بر اساس تعداد کاراکتر

در این روش، متن بر اساس تعداد مشخصی از کاراکترها تقسیم می‌شود.

۲ .تقسیم‌بندی بر اساس تعداد توکن

در این روش، اندازه قطعات با توجه به تعداد توکن‌های متنی تعیین می‌شود.

۳ .تقسیم‌بندی بر اساس پاراگراف

در این روش، مرز پاراگراف‌ها برای ایجاد قطعات مورد استفاده قرار می‌گیرد.

۴ .تقسیم‌بندی بر اساس ساختار سند

در این روش، تیترها، فصل‌ها و بخش‌های معنایی سند مبنای تقسیم‌بندی قرار می‌گیرند.

۵ .تقسیم‌بندی معنایی(Semantic Chunking)

در این روش، متن بر اساس تغییر موضوع و مفهوم به بخش‌های مختلف تقسیم می‌شود.

اهمیت اندازه قطعات

اگر قطعات بیش از اندازه کوچک باشند، ممکن است اطلاعات ضروری و ارتباط معنایی میان جملات از بین برود.

اگر قطعات بیش از اندازه بزرگ باشند، ممکن است اطلاعات نامرتبط وارد زمینه مدل شود و هزینه پردازش افزایش پیدا کند.

به همین دلیل، انتخاب اندازه مناسب Chunk باید با توجه به نوع داده و کاربرد سیستم انجام شود.

همچنین گاهی از هم‌پوشانی قطعات (Chunk Overlap) استفاده می‌شود. در این روش بخشی از انتهای یک قطعه در ابتدای قطعه بعدی تکرار می‌شود تا پیوستگی اطلاعات حفظ شود.

##۵-۵ .مدل تعبیه‌سازی(Embedding Model)

پس از تقسیم‌بندی اسناد، هر قطعه باید به یک بردار عددی تبدیل شود.

این کار با استفاده از مدل Embedding انجام می‌شود.

مدل‌های Embedding تلاش می‌کنند معنای متن را در قالب بردارهای چندبعدی نمایش دهند.

برای مثال، دو عبارت «خودروی الکتریکی» و «ماشین برقی» از نظر معنایی بسیار نزدیک هستند. بنابراین، بردارهای تولیدشده برای آن‌ها نیز معمولاً شباهت بالایی دارند.

انتخاب مدل Embedding مناسب اهمیت زیادی دارد.

در انتخاب این مدل باید به عوامل زیر توجه کرد:

-دقت درک معنایی
-پشتیبانی از زبان فارسی
-کیفیت عملکرد در متون تخصصی
-سرعت پردازش

-هزینه استفاده
-ابعاد بردار خروجی
-امکان اجرای محلی یا ابری

در سامانه‌های فارسی، استفاده از مدلی که به‌طور مناسب روی داده‌های فارسی یا چندزبانه ارزیابی شده باشد اهمیت ویژه‌ای دارد.

۵-۶. پایگاه داده برداری (Vector Database)

پس از تبدیل اسناد به بردار، این بردارها باید ذخیره شوند.

پایگاه داده برداری برای این منظور استفاده می‌شود.

این پایگاه داده معمولاً علاوه بر بردار، اطلاعات دیگری مانند متن اصلی، شناسه سند، عنوان، تاریخ انتشار و سایر فراداده‌ها را نیز نگهداری می‌کند.

هنگامی که کاربر پرسشی مطرح می‌کند، سیستم بردار پرسش را با بردارهای ذخیره‌شده مقایسه می‌کند.

سپس نزدیک‌ترین نتایج را انتخاب می‌کند.

برای این کار از الگوریتم‌های مختلفی استفاده می‌شود.

یکی از الگوریتم‌های رایج، HNSW است که برای جست‌وجوی تقریبی نزدیک‌ترین همسایه‌ها استفاده می‌شود.

۵-۷. بازیاب اطلاعات (Retriever)

Retriever یکی از اجزای کلیدی معماری RAG است.

وظیفه این بخش پیدا کردن اطلاعاتی است که بیشترین ارتباط را با پرسش کاربر دارند.

به زبان ساده، Retriever مانند یک کتابدار هوشمند عمل می‌کند که از میان حجم زیادی از اسناد، بخش‌های مناسب را پیدا می‌کند.

Retriever می‌تواند بر اساس جست‌وجوی برداری، جست‌وجوی کلمه‌محور یا ترکیبی از این دو کار کند.

کیفیت عملکرد Retriever اهمیت بسیار زیادی دارد؛ زیرا حتی اگر مدل زبانی قدرتمندی در اختیار داشته باشیم، اطلاعات بازیابی‌شده نامرتبط می‌توانند باعث تولید پاسخ اشتباه شوند.

۵-۸. مدل زبانی مولد (Generator)

مدل زبانی مولد مسئول تولید پاسخ نهایی است.

پس از بازیابی اسناد، سیستم آن‌ها را همراه با پرسش کاربر در قالب یک ورودی مشخص به مدل زبانی ارسال می‌کند.

مدل با تحلیل این اطلاعات، پاسخ نهایی را تولید می‌کند.

در این مرحله، طراحی Prompt اهمیت زیادی دارد.

Promptباید به مدل توضیح دهد:

-سؤال کاربر چیست؟
-اطلاعات مرجع کدام هستند؟
-پاسخ باید بر اساس چه منابعی تولید شود؟
-در صورت نبود اطلاعات کافی چه کاری انجام دهد؟
-پاسخ با چه ساختاری ارائه شود؟
-آیا باید به منابع استناد کند؟

برای مثال، می‌توان به مدل دستور داد که تنها از اطلاعات موجود در اسناد استفاده کند و در صورت نبود شواهد کافی، اعلام کند که پاسخ در منابع موجود نیست.

##۹-۵ Prompt Engineering .

Prompt Engineeringبه فرآیند طراحی و بهینه‌سازی دستورهایی گفته می‌شود که به مدل زبانی داده می‌شوند.

در سیستمRAG ، Promptباید به‌گونه‌ای طراحی شود که مدل بتواند اطلاعات بازیابی‌شده را به‌درستی تفسیر کند.

یک نمونه دستور مناسب به شکل زیر است:

»شما یک دستیار هوشمند هستید. با استفاده از اطلاعات ارائه‌شده در بخش منابع، به پرسش کاربر پاسخ دهید. اطلاعاتی خارج از منابع را به‌عنوان واقعیت مطرح نکنید. اگر اطلاعات کافی وجود ندارد، صریحاً اعلام کنید که پاسخ در اسناد موجود یافت نشد. در پایان، منابع مورد استفاده را مشخص کنید«.

این دستور می‌تواند به کاهش پاسخ‌های بدون پشتوانه کمک کند؛ البته تضمین‌کننده حذف کامل خطا نیست.

#فصل ششم: مراحل عملکرد سیستمRAG

عملکرد یک سیستم RAG را می‌توان به دو فرآیند اصلی تقسیم کرد: آماده‌سازی دانش و پاسخ‌گویی به کاربر.

##۱-۶ .مرحله اول: آماده‌سازی دانش

این مرحله معمولاً پیش از دریافت پرسش کاربر انجام می‌شود.

در ابتدا، اسناد مورد نیاز جمع‌آوری می‌شوند. سپس اطلاعات آن‌ها استخراج و پاک‌سازی می‌شود.

در ادامه، اسناد به قطعات کوچک‌تر تقسیم شده و هر قطعه توسط مدل Embedding به بردار تبدیل می‌شود.

بردارهای تولیدشده همراه با متن و فراداده‌های مربوطه در پایگاه داده ذخیره می‌شوند.

در این مرحله، یک پایگاه دانش قابل جست‌وجو ایجاد می‌شود.

۶-۲. مرحله دوم: دریافت پرسش کاربر

هنگامی که کاربر سؤالی را وارد می‌کند، سیستم آن را دریافت می‌کند.

برای مثال:

«شرایط دریافت مرخصی سالانه در شرکت چیست؟»

در یک سیستم سازمانی مبتنی برRAG ، پاسخ این سؤال باید از آیین‌نامه‌ها و دستورالعمل‌های داخلی شرکت استخراج شود.

۶-۳. مرحله سوم: تبدیل پرسش به بردار

پرسش کاربر به وسیله همان مدل Embedding یا مدلی سازگار با فضای برداری اسناد، به بردار عددی تبدیل می‌شود.

این بردار نشان‌دهنده مفهوم معنایی سؤال است.

۶-۴. مرحله چهارم: جست‌وجو در پایگاه داده

بردار پرسش در پایگاه داده برداری جست‌وجو می‌شود.

سیستم اسنادی را که بیشترین شباهت را به پرسش دارند انتخاب می‌کند.

برای مثال، ممکن است سه قطعه از آیین‌نامه مرخصی، قرارداد استخدامی و دستورالعمل منابع انسانی بازیابی شوند.

۶-۵. مرحله پنجم: رتبه‌بندی مجدد نتایج

گاهی نتایج اولیه جست‌وجو کاملاً دقیق نیستند.

به همین دلیل، از بخشی به نام Reranker استفاده می‌شود.

Rerankerنتایج بازیابی‌شده را دوباره بررسی می‌کند و آن‌ها را بر اساس میزان ارتباط واقعی با پرسش مرتب می‌کند.

در این مرحله، ممکن است قطعه‌ای که در جست‌وجوی اولیه رتبه پایینی داشته است، به رتبه بالاتری منتقل شود.

۶-۶ .مرحله ششم: ساخت زمینه(Context Construction)

پس از انتخاب اسناد مناسب، اطلاعات آن‌ها در قالب یک متن منظم کنار هم قرار می‌گیرند.

این اطلاعات همراه با پرسش کاربر به مدل زبانی ارسال می‌شوند.

سیستم باید مراقب باشد که حجم اطلاعات از محدودیت ورودی مدل فراتر نرود.

۶-۷ .مرحله هفتم: تولید پاسخ

مدل زبانی با استفاده از پرسش و اطلاعات بازیابی‌شده، پاسخ نهایی را تولید می‌کند.

در این مرحله، مدل باید تلاش کند اطلاعات موجود را به شکلی قابل فهم، منسجم و مرتبط ارائه دهد.

۶-۸ .مرحله هشتم: ارائه منابع و پاسخ نهایی

در یک سیستم RAG مناسب، بهتر است پاسخ نهایی همراه با مشخصات اسناد مورد استفاده ارائه شود.

برای مثال، سیستم می‌تواند نام سند، شماره صفحه و بخش مرتبط را نمایش دهد.

این قابلیت به کاربر اجازه می‌دهد اطلاعات را بررسی کند و از صحت پاسخ اطمینان بیشتری به دست آورد.

فصل هفتم: بررسی روش‌های بازیابی اطلاعات

۷-۱ .جست‌وجوی کلمه‌محور(Keyword Search)

در این روش، سیستم بر اساس تطبیق کلمات موجود در پرسش با کلمات موجود در اسناد جست‌وجو می‌کند.

یکی از الگوریتم‌های معروف در این زمینه BM25 است.

BM25یکی از الگوریتم‌های رتبه‌بندی در بازیابی اطلاعات محسوب می‌شود و از عواملی مانند فراوانی واژه و طول سند برای محاسبه امتیاز استفاده می‌کند.

مزیت این روش سرعت و عملکرد مناسب آن در جست‌وجوی اصطلاحات دقیق است.

با این حال، ممکن است نتواند ارتباط معنایی میان عبارت‌های متفاوت را به‌خوبی تشخیص دهد.

۷-۲. جست‌وجوی برداری(Vector Search)

در جست‌وجوی برداری، متن‌ها ابتدا به بردارهای عددی تبدیل می‌شوند.

سپس سیستم با محاسبه میزان شباهت میان بردار پرسش و بردار اسناد، مرتبط‌ترین نتایج را پیدا می‌کند.

یکی از معیارهای رایج، شباهت کسینوسی (Cosine Similarity) است.

فرمول شباهت کسینوسی به شکل زیر است:

$$
\operatorname{CosSim}(A,B)=
\frac{A\cdot B}{\|A\|\|B\|}
$$

در این فرمول، Aو B دو بردار هستند.

مقدار شباهت کسینوسی معمولاً بین ۱- و ۱ قرار می‌گیرد. مقدار نزدیک به ۱ نشان‌دهنده شباهت جهت دو بردار است.

جست‌وجوی برداری برای یافتن متونی که از نظر مفهومی مرتبط هستند، بسیار مفید است.

۷-۳. جست‌وجوی ترکیبی(Hybrid Search)

جست‌وجوی ترکیبی از دو روش Keyword Search و Vector Search به‌صورت هم‌زمان یا هماهنگ استفاده می‌کند.

هدف این روش بهره‌گیری از مزایای هر دو نوع جست‌وجو است.

برای مثال، فرض کنید کاربر درباره استانداردی با کد مشخص سؤال می‌کند.

جست‌وجوی کلمه‌محور می‌تواند کد استاندارد را دقیق پیدا کند، در حالی که جست‌وجوی برداری می‌تواند اسناد مرتبط از نظر معنایی را نیز شناسایی کند.

ترکیب این دو روش می‌تواند کیفیت بازیابی را افزایش دهد.

۷-۴. Reranking

Rerankingبه معنای رتبه‌بندی مجدد نتایج بازیابی‌شده است.

در بسیاری از سیستم‌ها، Retrieverابتدا تعدادی سند را به‌صورت سریع پیدا می‌کند.

سپس مدل رتبه‌بند این اسناد را با توجه به ارتباط دقیق‌ترشان با سؤال کاربر بررسی می‌کند.

استفاده از Reranking می‌تواند باعث شود اطلاعات مناسب‌تری به مدل زبانی ارسال شود.

۷-۵Query Expansion .

در این روش، سیستم پرسش کاربر را گسترش می‌دهد و عبارت‌های جایگزین یا مرتبط با آن را تولید می‌کند.

برای مثال، اگر کاربر عبارت «امنیت اطلاعات» را وارد کند، سیستم می‌تواند عبارت‌هایی مانند «حفاظت از داده‌ها»، «امنیت سایبری» و «مدیریت دسترسی» را نیز برای جست‌وجو در نظر بگیرد.

این کار می‌تواند احتمال پیدا کردن اسناد مرتبط را افزایش دهد.

۷-۶Query Rewriting .

گاهی پرسش کاربر مبهم، طولانی یا از نظر ساختار نامناسب است.

در این حالت، سیستم می‌تواند سؤال را بازنویسی کند تا برای موتور بازیابی مناسب‌تر شود.

برای مثال، پرسش:

»اون چیزی که درباره تعطیلات کارکنان توی فایل‌ها نوشته بود چی بود؟«

می‌تواند به شکل زیر بازنویسی شود:

»قوانین و شرایط استفاده از مرخصی کارکنان طبق آیین‌نامه شرکت چیست؟«

۷-۷HyDE .

روش HyDE مخفف Hypothetical Document Embeddings است.

در این روش، سیستم ابتدا با کمک یک مدل زبانی، یک متن فرضی مرتبط با پرسش تولید می‌کند.

سپس به جای استفاده مستقیم از بردار پرسش اولیه، بردار متن فرضی برای بازیابی اسناد به کار گرفته می‌شود.

هدف این روش بهبود تطبیق معنایی میان پرسش کاربر و اسناد موجود است.

با این حال، متن فرضی ممکن است شامل اطلاعات نادرست باشد؛ بنابراین، نتیجه بازیابی همچنان باید با اسناد واقعی کنترل شود.

#فصل هشتم: انواع معماری‌هایRAG

معماری RAG در طول زمان توسعه پیدا کرده و امروزه انواع مختلفی از آن وجود دارد.

##۸-۱ Naive RAG .

Naive RAGساده‌ترین نوع معماری RAG است.

در این معماری، اسناد به قطعات کوچک تقسیم شده و به بردار تبدیل می‌شوند.

سپس با دریافت پرسش کاربر، اسناد مرتبط بازیابی شده و به مدل زبانی ارسال می‌شوند.

این معماری دارای ساختار ساده‌ای است و برای پروژه‌های اولیه مناسب محسوب می‌شود.

مهم‌ترین محدودیت آن این است که ممکن است اسناد نامرتبط یا ناقص بازیابی شوند.

##۸-۲ Advanced RAG .

Advanced RAGنسخه پیشرفته‌تری از معماری ساده است.

در این ساختار، قبل و بعد از بازیابی اطلاعات، مراحل پردازشی بیشتری انجام می‌شود.

از جمله تکنیک‌های مورد استفاده در این معماری می‌توان به موارد زیر اشاره کرد:

- Query Rewriting
- Query Expansion
- Hybrid Search
- Reranking
- Semantic Chunking
- Metadata Filtering
- Context Compression

هدف این تکنیک‌ها افزایش دقت بازیابی و بهبود کیفیت پاسخ نهایی است.

##۸-۳ Modular RAG .

درModular RAG ، معماری به مجموعه‌ای از ماژول‌های مستقل تقسیم می‌شود.

هر ماژول وظیفه مشخصی دارد و می‌تواند به‌صورت جداگانه طراحی، بهینه‌سازی یا جایگزین شود.

برای مثال، ماژول‌های بازیابی، رتبه‌بندی، پردازش پرسش، تولید پاسخ و ارزیابی می‌توانند ساختارهای مستقلی داشته باشند.

این طراحی انعطاف‌پذیری بیشتری ایجاد می‌کند.

۸-۴ Graph RAG .

Graph RAGنوعی معماری است که از گراف دانش برای نمایش ارتباط میان موجودیت‌ها و مفاهیم استفاده می‌کند.

در پایگاه دانش گرافی، اطلاعات به‌صورت گره‌ها و ارتباط میان آن‌ها نمایش داده می‌شوند.

برای مثال، در یک سامانه سازمانی ممکن است:

-یک گره نماینده کارمند باشد.
-یک گره نماینده واحد سازمانی باشد.
-یک گره نماینده پروژه باشد.
-ارتباط میان گره‌ها نشان‌دهنده عضویت یا همکاری باشد.

این ساختار برای پرسش‌هایی که نیازمند بررسی روابط میان چند مفهوم هستند مفید است.

برای نمونه:

»کدام کارکنان در پروژه‌هایی فعالیت دارند که مدیر آن‌ها عضو واحد فناوری اطلاعات است؟«

پاسخ به چنین پرسشی ممکن است نیازمند پیمایش چند رابطه در گراف باشد.

Graph RAGدر برخی کاربردها می‌تواند درک ارتباطات پیچیده را نسبت به جست‌وجوی صرفاً برداری بهبود دهد.

۸-۵ Agentic RAG .

در معماریAgentic RAG ، از عامل‌های هوشمند برای مدیریت فرآیند بازیابی و تولید پاسخ استفاده می‌شود.

این عامل‌ها می‌توانند تصمیم بگیرند که:

-آیا بازیابی اطلاعات لازم است؟
-کدام منبع باید جست‌وجو شود؟
-آیا نتایج کافی هستند؟

-آیا باید پرسش بازنویسی شود؟
-آیا جست‌وجوی مجدد لازم است؟
-آیا پاسخ نهایی آماده است؟

این معماری برای وظایف پیچیده و چندمرحله‌ای مناسب است.

البته استفاده از عامل‌های هوشمند می‌تواند هزینه محاسباتی و پیچیدگی سیستم را افزایش دهد.

##۸-۶ Multimodal RAG .

در RAG سنتی، تمرکز اصلی بر اسناد متنی است.

اما در Multimodal RAG ، منابع اطلاعاتی می‌توانند شامل تصویر، صوت، ویدئو و متن باشند.

برای مثال، یک سیستم پزشکی می‌تواند علاوه بر اسناد متنی، از تصاویر پزشکی نیز برای بازیابی اطلاعات مرتبط استفاده کند.

یا یک سیستم آموزشی می‌تواند از محتوای ویدئوهای آموزشی برای پاسخ‌گویی به سؤالات دانشجویان استفاده کند.

این معماری زمینه استفاده از RAG را در کاربردهای پیچیده‌تر فراهم می‌کند.

#فصل نهم: پایگاه‌های داده برداری و نقش آن‌ها در RAG

##۹-۱ .اهمیت پایگاه داده برداری

پایگاه داده برداری یکی از اجزای اساسی سیستم‌های RAG است.

بدون یک روش مناسب برای ذخیره و جست‌وجوی بردارها، بازیابی سریع اطلاعات از مجموعه‌های بزرگ داده دشوار خواهد بود.

در پروژه‌های کوچک ممکن است بتوان از جست‌وجوی مستقیم روی بردارها استفاده کرد، اما با افزایش حجم اطلاعات، بهینه‌سازی جست‌وجو اهمیت بیشتری پیدا می‌کند.

##۹-۲ .الگوریتم‌های جست‌وجوی برداری

یکی از روش‌های رایج جست‌وجو، K-Nearest Neighbors یا KNN است.

در این روش، نزدیک‌ترین بردارها نسبت به بردار پرسش پیدا می‌شوند.

با افزایش تعداد بردارها، جست‌وجوی دقیق ممکن است پرهزینه شود.

به همین دلیل، از روش‌های Approximate Nearest Neighbor یا ANN استفاده می‌شود.

این روش‌ها تلاش می‌کنند نزدیک‌ترین نتایج را با سرعت بیشتر پیدا کنند، حتی اگر همیشه دقیق‌ترین همسایه‌ها را برنگردانند.

از الگوریتم‌های مهم این حوزه می‌توان به موارد زیر اشاره کرد:

- HNSW
- IVF
- Product Quantization
- ScaNN

##۳-۹ .مقایسه برخی پایگاه‌های داده برداری

FAISS:کتابخانه‌ای برای جست‌وجوی سریع شباهت برداری است که توسط Meta توسعه یافته است. این ابزار برای ساخت سامانه‌های بازیابی برداری بسیار کاربردی است.

Chroma:پایگاه داده‌ای است که برای کاربردهای هوش مصنوعی و مدیریتEmbedding ها استفاده می‌شود و در پروژه‌های نمونه‌سازی RAG محبوب است.

Qdrant:پایگاه داده برداری با قابلیت جست‌وجوی شباهت، فیلترگذاری و مدیریت فراداده است.

Milvus:پایگاه داده برداری متن‌باز است که برای مدیریت مجموعه‌های بزرگ برداری طراحی شده است.

Weaviate:پایگاه داده‌ای با امکانات جست‌وجوی برداری و ترکیب قابلیت‌های جست‌وجوی معنایی و ساختاری است.

Pinecone:یک سرویس مدیریت پایگاه داده برداری است که برای ساخت برنامه‌های مبتنی بر بازیابی اطلاعات استفاده می‌شود.

انتخاب میان این ابزارها به عواملی مانند حجم داده، هزینه، مقیاس‌پذیری، امکانات مدیریتی و شرایط استقرار بستگی دارد.

#فصل دهم: مقایسه RAG با روش‌های سنتی وFine-Tuning

##۱۰-۱ .تفاوت RAG و مدل زبانی معمولی

در مدل زبانی معمولی، پاسخ بر اساس اطلاعاتی تولید می‌شود که در فرآیند آموزش مدل یاد گرفته شده‌اند.

اما درRAG ، مدل می‌تواند هنگام پاسخ‌گویی به اطلاعات خارجی نیز دسترسی داشته باشد.

برای مثال، اگر کاربر درباره دستورالعمل داخلی یک شرکت سؤال کند، مدل معمولی ممکن است اطلاعاتی عمومی ارائه دهد؛ ولی سیستم RAG می‌تواند اسناد واقعی شرکت را جست‌وجو کرده و پاسخ خود را بر اساس آن‌ها تولید کند.

۱۰-۲. تفاوت RAG وFine-Tuning

Fine-Tuningبه فرآیند آموزش مجدد یا تنظیم یک مدل از پیش آموزش‌دیده با استفاده از داده‌های خاص گفته می‌شود.

هدف از این فرآیند می‌تواند بهبود سبک پاسخ‌گویی، یادگیری یک وظیفه تخصصی یا سازگار کردن مدل با یک حوزه مشخص باشد.

در مقابل، RAGبه‌جای تغییر مستقیم پارامترهای مدل، اطلاعات مورد نیاز را هنگام پاسخ‌گویی در اختیار آن قرار می‌دهد.

جدول زیر تفاوت این دو روش را نشان می‌دهد:

معیار	Fine-Tuning	RAG
روش اصلی	بازیابی دانش خارجی	تنظیم پارامترهای مدل
به‌روزرسانی دانش	معمولاً سریع‌تر	نیازمند آموزش مجدد یا تنظیم جدید
دسترسی به اسناد جدید	مستقیم از طریق پایگاه دانش	وابسته به داده‌های آموزش
ارائه منبع	امکان ارجاع به اسناد	به‌صورت ذاتی محدود
هزینه اولیه	ساخت زیرساخت بازیابی	هزینه آموزش و محاسبات
کاربرد مناسب	دانش متغیر و اسناد اختصاصی	رفتار و سبک تخصصی
وابستگی به پایگاه داده	معمولاً دارد	الزاماً ندارد

۱۰-۳. آیا می‌توان از RAG و Fine-Tuning به‌صورت هم‌زمان استفاده کرد؟

بله. این دو فناوری رقیب مطلق یکدیگر نیستند.

در برخی پروژه‌ها، ترکیب آن‌ها می‌تواند نتیجه بهتری ارائه دهد.

برای مثال، یک مدل ممکن است با Fine-Tuning برای پاسخ‌گویی تخصصی در حوزه حقوق آموزش داده شود و در عین حال با استفاده از RAGبه آخرین اسناد و قوانین دسترسی داشته باشد.

در این حالت:

Fine-Tuning -به بهبود رفتار و تخصص مدل کمک می‌کند.
RAG -اطلاعات جدید و مستند را در اختیار مدل قرار می‌دهد.

بنابراین، انتخاب روش مناسب باید بر اساس نیاز پروژه انجام شود.

#فصل یازدهم: کاربردهای معماریRAG

##۱-۱۱ .کاربرد در سازمان‌ها و شرکت‌ها

یکی از مهم‌ترین کاربردهایRAG ، ایجاد دستیارهای هوشمند سازمانی است.

شرکت‌ها معمولاً حجم زیادی از اسناد داخلی دارند؛ مانند قراردادها، دستورالعمل‌ها، گزارش‌ها، آیین‌نامه‌ها و مستندات فنی.

با استفاده از RAG می‌توان این اطلاعات را در یک پایگاه دانش متمرکز ذخیره کرد.

کارکنان می‌توانند سؤالات خود را به زبان طبیعی مطرح کنند و پاسخ را بر اساس اسناد سازمان دریافت کنند.

برای مثال:

»مراحل درخواست خرید تجهیزات در شرکت چیست؟«

سیستم می‌تواند دستورالعمل خرید را بازیابی کرده و مراحل را توضیح دهد.

##۲-۱۱ .کاربرد در آموزش و دانشگاه

RAGمی‌تواند در طراحی دستیارهای آموزشی هوشمند استفاده شود.

در این سامانه‌ها، کتاب‌ها، جزوه‌ها، مقالات و محتوای آموزشی در پایگاه دانش قرار می‌گیرند.

دانشجویان می‌توانند درباره مطالب درسی سؤال کنند و پاسخ‌هایی مبتنی بر منابع آموزشی دریافت کنند.

برای مثال، یک دانشجو می‌تواند بپرسد:

»تفاوت معماری RAG و Fine-Tuning چیست؟«

سامانه می‌تواند با استفاده از جزوه‌ها و منابع درسی، پاسخ مناسبی ارائه دهد.

##۳-۱۱ .کاربرد در پزشکی و سلامت

در حوزه پزشکی، اطلاعات بسیار زیادی در مقالات علمی، دستورالعمل‌های درمانی و منابع تخصصی وجود دارد.

سیستم‌های RAG می‌توانند به پزشکان و پژوهشگران در جست‌وجوی سریع‌تر اطلاعات کمک کنند.

برای مثال، یک سامانه می‌تواند بخش‌های مرتبط با یک بیماری را از میان مقالات علمی بازیابی کند.

با این حال، در حوزه پزشکی استفاده از این فناوری باید همراه با نظارت متخصصان، کنترل کیفیت منابع و رعایت الزامات حریم خصوصی باشد.

پاسخ سیستم نباید جایگزین تشخیص یا تصمیم‌گیری پزشک شود.

##۴-۱۱ .کاربرد در حقوق و امور قضایی

در حوزه حقوق، حجم زیادی از اطلاعات در قوانین، آیین‌نامه‌ها، بخشنامه‌ها و آرای قضایی وجود دارد.

RAGمی‌تواند برای جست‌وجوی مواد قانونی و اسناد مرتبط مورد استفاده قرار گیرد.

برای مثال، یک سامانه حقوقی می‌تواند بر اساس اسناد قانونی موجود، مواد مرتبط با یک موضوع را پیدا کرده و خلاصه‌ای از آن‌ها ارائه دهد.

در چنین کاربردی، نمایش شماره ماده، تاریخ سند و منبع اصلی اهمیت زیادی دارد.

##۵-۱۱ .کاربرد در بانکداری و امور مالی

مؤسسات مالی با حجم زیادی از اطلاعات، گزارش‌ها و دستورالعمل‌ها سروکار دارند.

RAGمی‌تواند برای جست‌وجوی گزارش‌های مالی، پاسخ‌گویی به پرسش‌های کارکنان و بازیابی اطلاعات مرتبط با خدمات بانکی استفاده شود.

همچنین می‌توان از این معماری برای ایجاد دستیارهای هوشمند مشتریان استفاده کرد.

##۶-۱۱ .کاربرد در پشتیبانی مشتریان

یکی دیگر از کاربردهای مهمRAG ، طراحی سامانه‌های پشتیبانی هوشمند است.

در این سامانه‌ها، اطلاعات محصولات، سؤالات متداول، راهنماها و دستورالعمل‌های پشتیبانی در پایگاه دانش ذخیره می‌شوند.

هنگامی که مشتری سؤالی مطرح می‌کند، سیستم اطلاعات مرتبط را پیدا کرده و پاسخ مناسب ارائه می‌دهد.

این کار می‌تواند زمان پاسخ‌گویی را کاهش دهد و کیفیت خدمات را افزایش دهد.

##۷-۱۱ .کاربرد در برنامه‌نویسی و فناوری اطلاعات

تیم‌های نرم‌افزاری معمولاً دارای مستندات فنی، کدهای برنامه‌نویسی، راهنماها و گزارش‌های خطا هستند.

با استفاده از RAG می‌توان سامانه‌ای ایجاد کرد که بر اساس مستندات داخلی به سؤالات برنامه‌نویسان پاسخ دهد.

برای مثال:

»روش احراز هویت در این پروژه چگونه پیاده‌سازی شده است؟«

سیستم می‌تواند بخش‌های مرتبط از مستندات و کدهای پروژه را بازیابی کند.

#فصل دوازدهم: مزایای استفاده ازRAG

##۱-۱۲ .کاهش احتمال توهم

یکی از مهم‌ترین مزایایRAG ، فراهم کردن امکان استفاده از شواهد خارجی هنگام تولید پاسخ است.

وقتی مدل به اسناد مرتبط دسترسی دارد، می‌تواند پاسخ خود را بر اساس اطلاعات موجود تنظیم کند.

این مسئله احتمال تولید اطلاعات ساختگی را کاهش می‌دهد، هرچند آن را به صفر نمی‌رساند.

##۲-۱۲ .به‌روزرسانی آسان اطلاعات

در سیستم‌های مبتنی برRAG ، برای افزودن اطلاعات جدید معمولاً کافی است اسناد جدید پردازش و در پایگاه داده ذخیره شوند.

در نتیجه، نیازی نیست مدل زبانی برای هر تغییر اطلاعاتی دوباره آموزش داده شود.

##۳-۱۲ .کاهش هزینه در بسیاری از کاربردها

Fine-Tuningمدل‌های بزرگ می‌تواند هزینه محاسباتی قابل‌توجهی داشته باشد.

در مقابل، RAGدر بسیاری از کاربردها امکان استفاده از مدل آماده را فراهم می‌کند.

البته ساخت و نگهداری زیرساخت بازیابی نیز هزینه دارد و در پروژه‌های بزرگ باید هزینه کلی سیستم بررسی شود.

##۴-۱۲ .امکان استفاده از اطلاعات خصوصی سازمان

با طراحی مناسب، اطلاعات داخلی یک سازمان می‌توانند در محیط کنترل‌شده نگهداری شوند و فقط در اختیار کاربران مجاز قرار گیرند.

این قابلیت برای شرکت‌هایی که اطلاعات اختصاصی دارند بسیار ارزشمند است.

##۵-۱۲ .افزایش شفافیت

یکی از ویژگی‌های مفیدRAG ، امکان نمایش منابعی است که پاسخ بر اساس آن‌ها تولید شده است.

این قابلیت باعث می‌شود کاربران بتوانند پاسخ را با اسناد اصلی مقایسه کنند.

##۶-۱۲ .انعطاف‌پذیری بالا

معماری RAG از اجزای مختلفی تشکیل شده است که می‌توان آن‌ها را تغییر داد.

برای مثال، سازمان می‌تواند مدلEmbedding ، پایگاه داده برداری یا مدل زبانی خود را بر اساس نیاز انتخاب کند.

#فصل سیزدهم: چالش‌ها و محدودیت‌های معماریRAG

با وجود مزایای متعدد، معماری RAG با چالش‌های مختلفی روبه‌رو است.

##۱-۱۳ .کیفیت پایین داده‌های اولیه

یکی از مهم‌ترین چالش‌ها، کیفیت منابع اطلاعاتی است.

اگر اسناد دارای اطلاعات نادرست، ناقص، تکراری یا قدیمی باشند، سیستم ممکن است نتایج نامناسبی تولید کند.

به همین دلیل، مدیریت کیفیت داده اهمیت زیادی دارد.

##۲-۱۳ .بازیابی اطلاعات نامرتبط

گاهی سیستم نمی‌تواند اسناد مناسب را پیدا کند.

این مشکل ممکن است به دلایل مختلفی رخ دهد:

-انتخاب نامناسب مدلEmbedding
-تقسیم‌بندی نادرست اسناد
-تنظیمات نامناسب جست‌وجو
-پرسش مبهم کاربر
-کیفیت پایین اسناد

اگر اطلاعات بازیابی‌شده نامرتبط باشند، مدل زبانی نیز ممکن است پاسخ اشتباهی تولید کند.

##۳-۱۳ .محدودیت پنجره زمینه

مدل‌های زبانی در هر درخواست فقط می‌توانند حجم مشخصی از اطلاعات را دریافت کنند.

به این محدودیت Context Window گفته می‌شود.

اگر سیستم تعداد زیادی سند بازیابی کند، ممکن است حجم اطلاعات از ظرفیت مدل بیشتر شود.

در چنین شرایطی، سیستم باید اطلاعات را اولویت‌بندی و خلاصه‌سازی کند.

۱۳-۴. هزینه پردازش

معماری RAG شامل چندین مرحله پردازشی است.

تبدیل متن به بردار، جست‌وجو، رتبه‌بندی مجدد و تولید پاسخ همگی ممکن است منابع محاسباتی مصرف کنند.

در سیستم‌های بزرگ، تعداد زیاد درخواست‌ها می‌تواند هزینه زیرساخت را افزایش دهد.

۱۳-۵. تأخیر در پاسخ‌گویی

در یک مدل زبانی معمولی، پرسش کاربر مستقیماً به مدل ارسال می‌شود.

اما در RAG ، ابتدا باید اطلاعات بازیابی شوند و سپس مدل پاسخ را تولید کند.

این فرآیند می‌تواند زمان پاسخ‌گویی را افزایش دهد.

برای کاهش تأخیر می‌توان از کش‌کردن نتایج، پایگاه داده بهینه و مدل‌های سریع‌تر استفاده کرد.

۱۳-۶. مشکل اطلاعات متناقض

ممکن است چند سند درباره یک موضوع اطلاعات متفاوتی ارائه دهند.

برای مثال، یک دستورالعمل قدیمی ممکن است شرایطی را بیان کند که در نسخه جدید تغییر کرده است.

در این شرایط، سیستم باید بتواند تاریخ، اعتبار و اولویت اسناد را تشخیص دهد.

استفاده از فراداده و قوانین مدیریت نسخه می‌تواند به حل این مشکل کمک کند.

۱۳-۷. وابستگی به مدل Embedding

اگر مدل Embedding نتواند معنای متن را به‌درستی نمایش دهد، جست‌وجوی معنایی نیز دچار مشکل می‌شود.

این موضوع به‌خصوص در زبان‌های کم‌منبع یا متون تخصصی اهمیت دارد.

۱۳-۸. خطا در تولید پاسخ

حتی اگر اطلاعات درست بازیابی شوند، مدل زبانی ممکن است آن‌ها را اشتباه تفسیر کند.

برای مثال، ممکن است دو عدد یا تاریخ را با یکدیگر اشتباه بگیرد یا نتیجه‌ای فراتر از اطلاعات موجود ارائه دهد.

بنابراین، کیفیت بازیابی به‌تنهایی برای تضمین پاسخ صحیح کافی نیست.

فصل چهاردهم: امنیت و حریم خصوصی در سیستم‌های RAG

۱۴-۱. اهمیت امنیت اطلاعات

در بسیاری از سیستم‌های RAG ، اطلاعات خصوصی و محرمانه سازمان‌ها ذخیره می‌شوند.

بنابراین، امنیت اطلاعات یکی از مهم‌ترین موضوعات در طراحی این معماری است.

اگر کنترل دسترسی به‌درستی انجام نشود، ممکن است کاربران به اطلاعاتی دسترسی پیدا کنند که مجاز به مشاهده آن‌ها نیستند.

۱۴-۲. کنترل دسترسی

یکی از راهکارهای مهم امنیتی، اعمال مجوزهای دسترسی در مرحله بازیابی است.

برای مثال، اگر یک کارمند فقط مجاز به مشاهده اسناد واحد خود باشد، سیستم باید هنگام جست‌وجو فقط اسناد مجاز را در اختیار او قرار دهد.

این موضوع را می‌توان با استفاده از Metadata Filtering و سیستم‌های مدیریت هویت پیاده‌سازی کرد.

نکته مهم آن است که کنترل دسترسی نباید صرفاً به دستورهای متنی داده‌شده به مدل وابسته باشد؛ بلکه باید در لایه برنامه و پایگاه داده نیز اعمال شود.

۱۴-۳. حملات Prompt Injection

یکی از خطرات مهم در سیستم‌های مبتنی بر مدل زبانی، حملات Prompt Injection است.

در این حملات، ممکن است متن مخربی در یک سند یا ورودی کاربر قرار داده شود که تلاش کند رفتار مدل را تغییر دهد.

برای مثال، یک سند مخرب ممکن است حاوی دستورهایی باشد که از مدل بخواهند اطلاعات محرمانه را افشا کند.

به همین دلیل، سیستم باید محتوای بازیابی‌شده را به‌عنوان داده غیرقابل اعتماد در نظر بگیرد، نه دستور اجرایی.

۱۴-۴. جلوگیری از نشت اطلاعات

برای جلوگیری از نشت اطلاعات باید موارد زیر رعایت شوند:

- رمزنگاری اطلاعات حساس
- کنترل دسترسی کاربران
- ثبت و بررسی فعالیت‌ها
- حذف داده‌های غیرضروری
- محدود کردن دسترسی مدل به ابزارها
- جداسازی اطلاعات کاربران مختلف
- بررسی امنیت سرویس‌های خارجی

۱۴-۵. مدیریت داده‌های حساس

در برخی کاربردها، اطلاعات شخصی مانند شماره تماس، نشانی، اطلاعات پزشکی و اطلاعات مالی در اسناد وجود دارند.

پیش از استفاده از چنین اطلاعاتی باید الزامات قانونی و سیاست‌های حفظ حریم خصوصی بررسی شوند.

همچنین بهتر است اطلاعات حساس در صورت عدم نیاز، پیش از ورود به فرآیند پردازش حذف یا ناشناس‌سازی شوند.

فصل پانزدهم: ارزیابی و سنجش عملکرد سیستم‌های RAG

ارزیابی یک سیستم RAG اهمیت بسیار زیادی دارد؛ زیرا عملکرد مناسب مدل زبانی به‌تنهایی نشان‌دهنده کیفیت کل سامانه نیست.

برای ارزیابی دقیق، باید هم بخش بازیابی اطلاعات و هم بخش تولید پاسخ بررسی شوند.

۱۵-۱. ارزیابی بخش بازیابی

در این بخش بررسی می‌شود که آیا سیستم توانسته است اسناد مرتبط را پیدا کند یا خیر.

از معیارهای مهم می‌توان به موارد زیر اشاره کرد:

Precision@K: نشان می‌دهد چه نسبتی از K نتیجه بازیابی‌شده مرتبط هستند.

Recall@K: نشان می‌دهد چه نسبتی از اسناد مرتبط واقعی در میان K نتیجه بازیابی‌شده قرار دارند.

MRR:میانگین معکوس رتبه اولین نتیجه مرتبط را اندازه‌گیری می‌کند.

nDCG:کیفیت رتبه‌بندی نتایج را با توجه به میزان ارتباط آن‌ها ارزیابی می‌کند.

۱۵-۲. ارزیابی بخش تولید پاسخ

در این مرحله، کیفیت پاسخ تولیدشده بررسی می‌شود.

معیارهای مهم عبارت‌اند از:

-میزان ارتباط پاسخ با سؤال
-صحت اطلاعات
-وفاداری به اسناد بازیابی‌شده
-کامل بودن پاسخ
-خوانایی و انسجام متن
-میزان اطلاعات بدون پشتوانه

۱۵-۳. معیارFaithfulness

Faithfulnessبه میزان وفاداری پاسخ تولیدشده به اطلاعات موجود در زمینه بازیابی‌شده اشاره دارد.

اگر مدل اطلاعاتی را ارائه کند که در اسناد وجود ندارد، میزان وفاداری پاسخ کاهش می‌یابد.

۱۵-۴. معیارAnswer Relevance

این معیار بررسی می‌کند که پاسخ تولیدشده تا چه اندازه به سؤال کاربر مرتبط است.

ممکن است پاسخ از نظر اطلاعاتی درست باشد، اما به سؤال اصلی کاربر پاسخ ندهد.

در چنین شرایطی، Answer Relevanceپایین خواهد بود.

۱۵-۵. چارچوبRAGAS

RAGASیکی از چارچوب‌های شناخته‌شده برای ارزیابی سیستم‌های RAG است.

این چارچوب مجموعه‌ای از معیارها برای بررسی کیفیت بازیابی و تولید پاسخ ارائه می‌کند.

از جمله معیارهای آن می‌توان به موارد زیر اشاره کرد:

- Faithfulness
- Answer Relevancy
- Context Precision
- Context Recall
- Answer Correctness

استفاده از چنین چارچوب‌هایی به توسعه‌دهندگان کمک می‌کند مشکلات سیستم را دقیق‌تر شناسایی کنند.

##۶-۱۵ .اهمیت ارزیابی انسانی

معیارهای خودکار برای ارزیابی سیستم‌های RAG مفید هستند، اما همیشه کافی نیستند.

در کاربردهای حساس، باید پاسخ‌های تولیدشده توسط متخصصان نیز بررسی شوند.

برای مثال، در سامانه حقوقی یا پزشکی، ارزیابی کارشناسان انسانی اهمیت ویژه‌ای دارد.

#فصل شانزدهم: نمونه عملی طراحی یک سامانه مبتنی برRAG

برای درک بهتر نحوه عملکرد معماریRAG ، یک نمونه کاربردی در نظر می‌گیریم.

##۱۶-۱ .تعریف مسئله

فرض کنید یک دانشگاه دارای تعداد زیادی فایلPDF ، آیین‌نامه آموزشی، برنامه درسی و دستورالعمل‌های اداری است.

دانشجویان برای پیدا کردن اطلاعات مورد نیاز خود مجبور هستند فایل‌های مختلف را جست‌وجو کنند.

هدف، طراحی یک دستیار هوشمند است که بتواند به سؤالات دانشجویان بر اساس اسناد رسمی دانشگاه پاسخ دهد.

##۱۶-۲ .انتخاب منابع اطلاعاتی

منابع اطلاعاتی سیستم عبارت‌اند از:

-آیین‌نامه آموزشی
-فایل‌های مربوط به انتخاب واحد
-قوانین حذف و اضافه
-دستورالعمل امتحانات
-مقررات خوابگاه
-اطلاعات مربوط به شهریه

-برنامه‌های آموزشی

تمام این فایل‌ها به‌عنوان منابع دانش سیستم در نظر گرفته می‌شوند.

۱۶-۳. استخراج اطلاعات

در مرحله بعد، متن فایل‌های PDF و Word استخراج می‌شود.

اگر فایل‌ها اسکن‌شده باشند، از OCR استفاده می‌شود.

سپس متن‌ها پاک‌سازی و ساختار آن‌ها اصلاح می‌شود.

۱۶-۴. تقسیم‌بندی و تبدیل به بردار

اسناد به قطعات مناسب تقسیم می‌شوند.

برای مثال، هر قطعه می‌تواند شامل یک یا چند پاراگراف مرتبط باشد.

سپس هر قطعه با استفاده از مدل Embedding به بردار تبدیل می‌شود.

۱۶-۵. ذخیره‌سازی

بردارها همراه با متن اصلی و اطلاعاتی مانند نام فایل، شماره صفحه، تاریخ و عنوان بخش در پایگاه داده برداری ذخیره می‌شوند.

۱۶-۶. دریافت پرسش

دانشجو سؤال زیر را مطرح می‌کند:

»برای حذف اضطراری یک درس چه شرایطی لازم است؟«

سیستم سؤال را دریافت می‌کند و آن را به بردار تبدیل می‌کند.

۱۶-۷. بازیابی اطلاعات

پایگاه داده برداری بخش‌های مرتبط با حذف اضطراری درس را پیدا می‌کند.

اگر سیستم از Hybrid Search استفاده کند، می‌تواند علاوه بر شباهت معنایی، عبارت‌های دقیق موجود در آیین‌نامه را نیز بررسی کند.

۱۶-۸. تولید پاسخ

اطلاعات بازیابی‌شده به مدل زبانی ارسال می‌شوند.

مدل با استفاده از اسناد، پاسخ را تولید می‌کند.

نمونه پاسخ:

»طبق آیین‌نامه آموزشی دانشگاه، حذف اضطراری درس تابع شرایط و مهلت‌های تعیین‌شده در تقویم آموزشی است. برای اطلاع از شرایط دقیق، باید بند مربوط به حذف اضطراری در نسخه معتبر آیین‌نامه بررسی شود«.

در این سامانه، بهتر است پاسخ همراه با نام سند و شماره صفحه ارائه شود.

##۹-۱۶ .مزایای سامانه پیشنهادی

-کاهش زمان جست‌وجوی اطلاعات
-افزایش دسترسی دانشجویان به قوانین
-کاهش حجم سؤالات تکراری از کارشناسان
-امکان به‌روزرسانی اسناد
-ارائه پاسخ مبتنی بر منابع رسمی
-امکان استفاده در تمام ساعات شبانه‌روز

این مثال نشان می‌دهد که معماری RAG می‌تواند در حل مسائل واقعی و سازمانی کاربرد داشته باشد.

#فصل هفدهم: آینده معماریRAG

با توجه به پیشرفت سریع مدل‌های زبانی بزرگ، انتظار می‌رود معماری RAG نیز در سال‌های آینده توسعه بیشتری پیدا کند.

##۱-۱۷ .افزایش هوشمندی بازیابی

یکی از مسیرهای مهم توسعهRAG ، استفاده از روش‌های هوشمندتر برای بازیابی اطلاعات است.

در سیستم‌های ساده، پرسش کاربر مستقیماً برای جست‌وجو استفاده می‌شود.

اما در سیستم‌های پیشرفته‌تر، مدل می‌تواند ابتدا پرسش را تحلیل کند، آن را به چند زیرپرسش تقسیم کند و سپس اطلاعات مورد نیاز را از منابع مختلف بازیابی کند.

این روش برای پرسش‌های پیچیده مفید است.

۱۷-۲. توسعه Agentic RAG

در آینده، عامل‌های هوشمند می‌توانند نقش بیشتری در مدیریت سیستم‌های RAG داشته باشند.

این عامل‌ها قادر خواهند بود مراحل مختلف بازیابی، بررسی نتایج، جست‌وجوی مجدد و تولید پاسخ را مدیریت کنند.

برای مثال، اگر یک پرسش نیازمند اطلاعات چند منبع باشد، عامل هوشمند می‌تواند منابع مختلف را بررسی و نتایج را ترکیب کند.

۱۷-۳. گسترش Multimodal RAG

با افزایش توانایی مدل‌های چندوجهی، سیستم‌های RAG نیز می‌توانند از انواع مختلف داده استفاده کنند.

برای مثال، در آینده می‌توان سامانه‌هایی طراحی کرد که به‌طور هم‌زمان از متن، تصویر، صدا و ویدئو اطلاعات بازیابی کنند.

این موضوع در حوزه آموزش، پزشکی، صنعت و نظارت تصویری کاربردهای فراوانی خواهد داشت.

۱۷-۴. بهبود امنیت و قابلیت اعتماد

با افزایش استفاده سازمان‌ها از RAG ، موضوع امنیت اهمیت بیشتری پیدا خواهد کرد.

انتظار می‌رود روش‌های پیشرفته‌تری برای کنترل دسترسی، جلوگیری از نشت اطلاعات، شناسایی اسناد مخرب و ارزیابی اعتبار منابع توسعه پیدا کنند.

۱۷-۵. استفاده از Graph RAG

در آینده، استفاده از گراف‌های دانش می‌تواند در پاسخ‌گویی به پرسش‌های پیچیده نقش مهمی داشته باشد.

این روش امکان تحلیل ارتباط میان مفاهیم و موجودیت‌ها را فراهم می‌کند.

۱۷-۶. توسعه RAG در زبان فارسی

یکی از زمینه‌های مهم توسعه این فناوری، بهبود عملکرد آن در زبان فارسی است.

برای این منظور باید مدل‌های Embedding مناسب‌تر، روش‌های پردازش متون فارسی و ابزارهای بازیابی معنایی دقیق‌تر توسعه پیدا کنند.

همچنین مدیریت نیم‌فاصله، شکل‌های مختلف نگارش کلمات، متون راست‌به‌چپ و اسناد فارسی دارای جدول و تصویر از مسائل مهم این حوزه هستند.

۱۷-۷. حرکت به سمت سامانه‌های دانش‌محور قابل اعتماد

هدف نهایی توسعه RAG تنها تولید پاسخ‌های سریع‌تر نیست.

یکی از اهداف مهم، ایجاد سامانه‌هایی است که بتوانند پاسخ‌های مستند، قابل بررسی و مبتنی بر منابع معتبر تولید کنند.

برای رسیدن به این هدف، باید کیفیت داده، بازیابی، استدلال، تولید پاسخ و ارزیابی به‌صورت یکپارچه مورد توجه قرار گیرند.

#فصل هجدهم: نتیجه‌گیری

معماری Retrieval-Augmented Generation یکی از فناوری‌های مهم در توسعه نسل جدید سیستم‌های هوش مصنوعی محسوب می‌شود. این معماری با ترکیب قابلیت بازیابی اطلاعات و تولید متن، امکان استفاده از منابع خارجی را برای مدل‌های زبانی بزرگ فراهم می‌کند.

مدل‌های زبانی بزرگ با وجود توانایی‌های گسترده، در برخی موارد با محدودیت‌هایی مانند اطلاعات قدیمی، نداشتن دسترسی به اسناد اختصاصی و تولید اطلاعات نادرست مواجه هستند. معماری RAG با اتصال این مدل‌ها به پایگاه‌های دانش خارجی تلاش می‌کند بخشی از این مشکلات را کاهش دهد.

در این تحقیق مشخص شد که معماری RAG از اجزای مختلفی مانند منابع داده، استخراج اطلاعات، پیش‌پردازش، تقسیم‌بندی اسناد، مدل‌های Embedding، پایگاه داده برداری، بازیاب اطلاعات، رتبه‌بند مجدد و مدل زبانی مولد تشکیل شده است.

هر یک از این اجزا نقش مهمی در عملکرد نهایی سیستم دارند. برای مثال، کیفیت تقسیم‌بندی اسناد بر کیفیت بازیابی تأثیر می‌گذارد و کیفیت بازیابی نیز بر پاسخ نهایی مدل اثرگذار است.

همچنین بررسی انواع معماری‌های RAG نشان داد که این فناوری از یک ساختار ساده بازیابی و تولید به مجموعه‌ای از روش‌های پیشرفته مانند Advanced RAG، Graph RAG، Agentic RAG و Multimodal RAG توسعه یافته است.

از مهم‌ترین کاربردهای این فناوری می‌توان به ساخت دستیارهای هوشمند سازمانی، سامانه‌های آموزشی، سیستم‌های پشتیبانی مشتریان، جست‌وجوی اسناد حقوقی، بازیابی اطلاعات پزشکی و سامانه‌های دانش‌محور اشاره کرد.

با وجود مزایای فراوان، RAGبا چالش‌هایی مانند کیفیت پایین داده‌ها، بازیابی نامرتبط، هزینه پردازش، تأخیر در پاسخ‌گویی، اطلاعات متناقض و خطرات امنیتی مواجه است.

بنابراین، طراحی یک سیستم RAG موفق نیازمند توجه هم‌زمان به کیفیت داده، انتخاب مدل مناسب، طراحی پایگاه دانش، روش بازیابی، امنیت و ارزیابی عملکرد است.

در نهایت می‌توان گفت RAG یکی از راهکارهای مهم برای حرکت از مدل‌های زبانی عمومی به سمت سامانه‌های هوش مصنوعی تخصصی و مبتنی بر دانش است. این فناوری به سازمان‌ها اجازه می‌دهد اطلاعات اختصاصی خود را در اختیار مدل‌های زبانی قرار دهند و از قابلیت‌های تولید متن و تحلیل زبان طبیعی برای دسترسی بهتر به دانش استفاده کنند.

با توجه به پیشرفت مداوم هوش مصنوعی، انتظار می‌رود معماری RAG در آینده نقش مهم‌تری در توسعه دستیارهای هوشمند، سامانه‌های تصمیم‌یار و نرم‌افزارهای مبتنی بر دانش ایفا کند.

#فصل نوزدهم: منابع و مراجع

. Lewis, P., Perez, E., Piktus, A., et al. (2020). *Retrieval-Augmented Generation for Knowledge-١
Intensive NLP Tasks*. Advances in Neural Information Processing Systems (NeurIPS 2020), 33, 9459–9474.

https://arxiv.org/abs/2005.11401

. Zhao, S., Yang, Y., Wang, Z., He, Z., Qiu, L. K., & Qiu, L. (2024). *Retrieval Augmented Generation ٢
(RAG) and Beyond: A Comprehensive Survey on How to Make your LLMs use External Data More Wisely*. Microsoft Research.

https://www.microsoft.com/en-us/research/publication/retrieval-augmented-generation-rag-and-beyond-a-comprehensive-survey-on-how-to-make-your-llms-use-external-data-more-wisely/

. Yang, X., et al. (2024). *CRAG: Comprehensive RAG Benchmark*. Advances in Neural Information ٣
Processing Systems (NeurIPS 2024).

https://proceedings.neurips.cc/paper_files/paper/2024/hash/1435d2d0fca85a84d83ddcb754f58c29-Abstract-Datasets_and_Benchmarks_Track.html

. Ru, D., et al. (2024). *RAGChecker: A Fine-grained Framework for Diagnosing Retrieval-Augmented ۴
Generation*. Advances in Neural Information Processing Systems (NeurIPS 2024).

https://proceedings.neurips.cc/paper_files/paper/2024/hash/27245589131d17368cccdfa990cbf16e-Abstract-Datasets_and_Benchmarks_Track.html

. FAISS Documentation. *A Library for Efficient Similarity Search and Clustering of Dense Vectors*.۵

https://github.com/facebookresearch/faiss

. Qdrant Documentation. *Vector Search Engine and Vector Database*.۶

https://qdrant.tech/documentation/

. Milvus Documentation. *Open-Source Vector Database*.٧

https://milvus.io/docs

. Chroma Documentation. *Open-Source AI Application Database*.٨

https://docs.trychroma.com/

. Weaviate Documentation. *AI-Native Vector Database*.٩

https://weaviate.io/developers/weaviate

. Pinecone Documentation. *Vector Database and Retrieval-Augmented Generation Resources*.١٠

https://docs.pinecone.io/

. RAGAS Documentation. *Evaluation Framework for Retrieval-Augmented Generation*.١١

https://docs.ragas.io/